

# Sprawozdanie P1.4

Kamil Tasarz, 322492

październik-listopad 2021

## 1 Wstęp

Stała Eulera, zwana również stałą Eulera-Mascheroniego jest stałą matematyczną oznaczaną  $\gamma = 0.577215664901532286 \dots$ . Jest zdefiniowana za pomocą granicy

$$\gamma := \lim_{n \rightarrow \infty} \gamma_n,$$

$$\text{gdzie } \gamma_n := 1 + \frac{1}{2} + \frac{1}{3} + \dots + \frac{1}{n} - \ln n.$$

Zakładając prawdziwość przybliżenia

$$\gamma_n - \gamma \approx cn^{-d}$$

dla dostatecznie dużych  $n$ , doświadczenie ma na celu wyznaczyć stałe  $c, d > 0$ . W tym sprawozdaniu omówię etapy i wyniki tego doświadczenia.

## 2 Nieco o regresji liniowej

Regresja liniowa jest metodą szacowania jednej zmiennej, gdy dysponujemy wartościami innej zmiennej przy założeniu, że zmienne te są od siebie zależne liniowo. Weźmy równanie liniowe

$$y = \beta_0 + \beta_1 x.$$

Chcemy dla pewnego zbioru danych, które mamy znaleźć współczynniki  $\beta_0, \beta_1$ . Dane są postaci  $(x_i, y_i)$ . Zapiszmy to w postaci układu:

$$\begin{cases} y_1 = \beta_0 + \beta_1 x_1 + \epsilon_1 \\ y_2 = \beta_0 + \beta_1 x_2 + \epsilon_2 \\ \vdots \\ y_n = \beta_0 + \beta_1 x_n + \epsilon_n, \end{cases}$$

gdzie  $\epsilon_i$  to błąd, który należy zminimalizować dobierając odpowiednie  $\beta_0, \beta_1$ .

Niech:

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}, \quad B = \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} \quad \text{oraz} \quad E = \begin{pmatrix} \epsilon_1 \\ \epsilon_2 \\ \vdots \\ \epsilon_n \end{pmatrix}$$

Możemy teraz zapisać nasz układ w postaci macierzowej

$$Y = XB + E.$$

Chcielibyśmy zminimalizować  $\sum_{i=1}^n \epsilon_i$ . Mamy

$$\sum_{i=1}^n \epsilon_i^2 = \sum_{i=1}^n (\beta_0 + \beta_1 x_i - y_i)^2$$

czyli

$$0 = \sum_{i=1}^n (\beta_0 + \beta_1 x_i - y_i)^2 - \sum_{i=1}^n \epsilon_i^2.$$

Funkcja ta osiąga swoje minimum w miejscu zerowania się pochodnych. Znajdźmy te punkty. Najpierw zróżniczkujemy po  $\beta_0$  i  $\beta_1$ .

$$0 = \sum_{i=1}^n 2(\beta_0 + \beta_1 x_i - y_i)$$

$$0 = \sum_{i=1}^n 2x_i(\beta_0 + \beta_1 x_i - y_i)$$

Po rozdzieleniu sum i uporządkowaniu dostajemy układ:

$$\beta_0 \sum_{i=1}^n 1 + \beta_1 \sum_{i=1}^n x_i = \sum_{i=1}^n y_i$$

$$\beta_0 \sum_{i=1}^n x_i + \beta_1 \sum_{i=1}^n x_i^2 = \sum_{i=1}^n x_i y_i$$

A po zapisaniu w postaci macierzowej:

$$\begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} \begin{pmatrix} \beta_0 \\ \beta_1 \end{pmatrix} = \begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix}$$

Zauważmy, że dla wcześniej zdefiniowanych macierzy

$$Y = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix}, \quad X = \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix}$$

zachodzą równości

$$\begin{pmatrix} \sum 1 & \sum x_i \\ \sum x_i & \sum x_i^2 \end{pmatrix} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} 1 & x_1 \\ 1 & x_2 \\ \vdots & \vdots \\ 1 & x_n \end{pmatrix} = XX^T$$

oraz

$$\begin{pmatrix} \sum y_i \\ \sum x_i y_i \end{pmatrix} = \begin{pmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \end{pmatrix} \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{pmatrix} = X^T Y$$

Po wstawieniu do równania otrzymujemy:

$$X^T X B = X^T Y,$$

a po przekształceniu:

$$B = (X^T X)^{-1} X^T Y \tag{1}$$

Jest to wzór na takie  $\beta_0, \beta_1$ , dla których suma  $\epsilon_i$  będzie najmniejsza. Czyli są to współczynniki najlepiej oddające zależność liniową  $y = \beta_0 + \beta_1 x$  dla danego zbioru zmiennych  $(x_i, y_i)$ .

### 3 Powiązanie z zadaniem

Uznajmy za prawdziwe przybliżenie

$$\gamma_n - \gamma \approx cn^{-d}.$$

Po zlogarytmowaniu dostajemy

$$\ln(\gamma_n - \gamma) \approx -d \ln(n) + \ln(c).$$

Jeśli potraktujemy  $\ln(\gamma_n - \gamma)$  jako zmienną  $y$ ,  $\ln(n)$  jako zmienną  $x$ , a szukane  $\ln(c)$  oraz  $-d$  kolejno jako współczynniki  $\beta_0$  i  $\beta_1$ . Dostajemy równanie (właściwie przybliżenie) liniowe. Kolejno korzystając ze wzoru (1), gdzie  $B = \begin{pmatrix} \ln(c) \\ -d \end{pmatrix}$ , dla dostatecznie dużych  $n$  możemy wyznaczyć doświadczalnie przybliżenie stałych  $c$  i  $d$ .

### 4 Program i pierwsze wyniki

Program jest napisany w języku Julia w wersji 1.6.3. Do obliczeń będę używał precyzji 256-bitowej, która zapewnia wystarczającą dokładność do osiągnięcia celu. Weźmy kilka macierzy  $X$ , odpowiadające im macierze  $Y$  i policzmy macierz  $B$ . Niech macierz  $X$  składa się z dziesięciu elementów  $x_i$  od  $10^i$  do  $10^{i+1}$ , czyli np. dla  $i = 3$  będą to liczby: 1000, 2000, 3000, ..., 10000.

$i$	$\ln(c)$	$e^{\ln(c)} = c$	$d$
1	-0.7209...	0.4862...	-0.9939...
2	-0.69728...	0.49793...	-0.99940...
3	-0.693698...	0.49972...	-0.999940...
4	-0.693216...	0.499965...	-0.9999940...
5	-0.693155...	0.49999587...	-0.99999940...
6	-0.6931481...	0.499999506...	-0.9999999387...
7	-0.69314676...	0.500000209...	-1.0000000238...

Już te kilka wyników pozwala nam przypuszczać, że szukane to  $d = 1$  oraz  $c = 0.5$ .

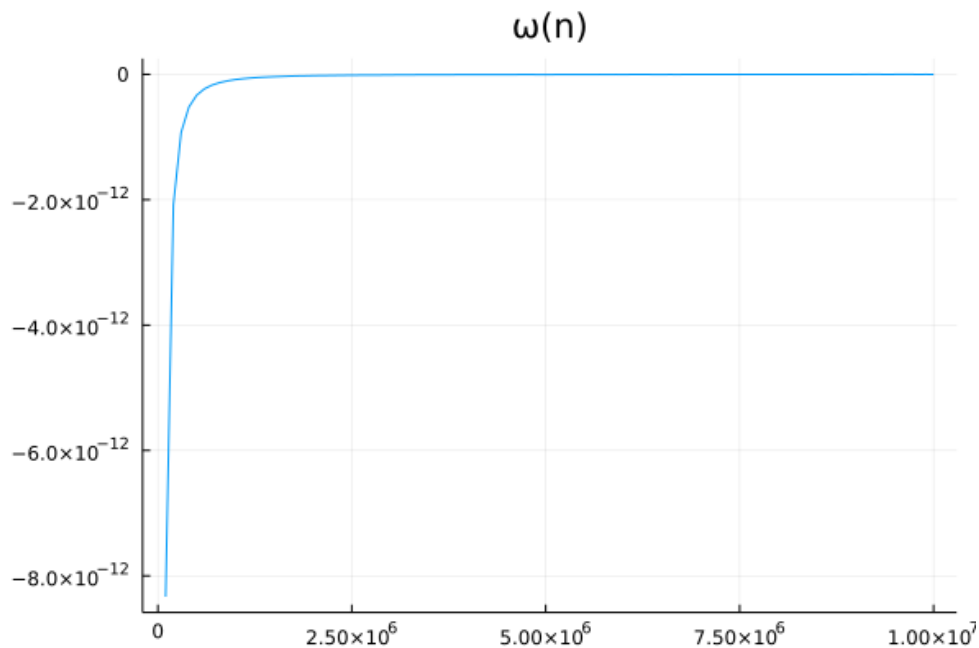
### 5 Potwierdzenie oszacowania

Udało nam się oszacować stałe  $c$  oraz  $d$ . Załóżmy, że są one poprawne, to jest, zgodnie z treścią naszego zadania, dla dostatecznie dużych  $n$ , zachodzi

$$\gamma_n - \gamma \approx \frac{1}{2n}.$$

Sprawdźmy jak zachowuje się wyrażenie  $\omega(n) = \gamma_n - \gamma - \frac{1}{2n}$ .

Jeśli stałe są wyznaczone dobrze to wyrażenie to powinno być w przybliżeniu równe 0 dla dużych  $n$ . Zobaczymy wykres:



Pomimo tego, że  $\omega(1)$  jest rzędu  $10^{-2}$  to zbliża się ona do zera szybko. Dla  $n$  rzędu  $10^4$   $\omega(n)$  jest rzędu  $10^{-10}$ . Wykres przedstawia wartości dla jeszcze większych  $n$ .

## 6 Podsumowanie

W tym doświadczeniu udało mi przybliżyć wyrażenie  $\gamma_n - \gamma \approx \frac{1}{2n}$ . Posłużyłem się metodą regresji liniowej wykorzystywanej w statystyce. Wyprowadziłem ogólny wzór i zastosowałem go do danego problemu. Na koniec, mając podejrzenia co do wartości szukanych stałych, sprawdziłem jak dobrze przybliżają one wyrażenie  $\gamma_n - \gamma$ .

## Literatura

- [1] Using matrix algebra in linear regresssion, Jackie Nicholas, Mathematics Learning Centre, University of Sydney (2010) - [link](#)
- [2] Bo Li's lecture script - [link](#)